


DATA SCIENCE Z

Sobrevivendo ao Apocalipse Zumbi
com Ciência de Dados em R



EDUARDO ARAUJO

Data Science Z

Sobrevivendo ao Apocalipse Zumbi com Ciência de Dados em R

Eduardo Araujo

26 de maio de 2026

Sumário

Prefácio	4
Quem Está Nessa História?	5
1 Introdução à Ciência de Dados	6
1.1 O Que é Ciência de Dados?	6
1.2 Por Que R?	7
2 Preparando o Ambiente	8
2.1 Instalando o R	8
2.2 Instalando o RStudio	9
2.3 Primeira Execução	9
2.4 Nosso Primeiro Script	10
I Como tudo começou	12
3 O Primeiro Surto	13
3.1 Dia 5 Após a Infecção	13
3.2 Seu Primeiro Vetor	13
3.3 Analisando os Dados	14
3.3.1 Estatística Descritiva: uma visão geral	14
3.3.2 O que cada função calcula	15
3.3.3 Medidas de posição: quartis	15
3.3.4 Interpretando os resultados	16
3.3.5 Visualizando os dados com um gráfico de linha	16
3.4 Instalando o Tidyverse	16
3.5 O Primeiro Dataset	17
3.6 Importando Dados	17
3.7 Resumo Estatístico	18
3.8 Visualizando a Catástrofe	18
3.9 Missão do Capítulo	19
3.10 Fim do Dia	19
4 A Curva Que Ninguém Viu	20
4.1 O Que é um Histograma?	20
4.2 Por Que Isso Importa?	21
4.3 Construindo um Histograma em R	21
4.4 O Que é uma Distribuição de Probabilidade?	22

4.5	Variáveis Discretas e Contínuas	23
4.6	Distribuição Normal	23
4.6.1	Os dois parâmetros da distribuição normal	24
4.7	A Regra 68–95–99,7	24
4.8	Missão do Capítulo	25
5	O Quanto Você Pode Errar	26
5.1	O Problema da Média	26
5.2	A Ideia por Trás do Desvio Padrão	27
5.3	Calculando em R	27
5.4	De Volta aos Infectados	28
5.5	Uma Nota Sobre Amostras	29
5.6	Missão do Capítulo	29

Prefácio

A civilização caiu.
As cidades queimaram.
Os hospitais lotaram.
Os governos desapareceram.
Mas os dados permaneceram.

Este livro ensina Ciência de Dados com R. Mas não vai fazer isso com slides corporativos nem com exemplos de vendas de sorvete no verão.

Vai fazer isso no fim do mundo.

Em cada capítulo, você vai acompanhar três sobreviventes tentando usar dados para entender — e talvez conter — o colapso da humanidade. Eles não são heróis. São pessoas comuns com acesso a um computador, uma instalação de R e perguntas que precisam de resposta urgente.

Ao longo da história, você vai aprender estatística descritiva, histogramas, distribuições de probabilidade e muito mais — não como abstrações, mas como ferramentas que Taís, Renato e Conceição precisam dominar para sobreviver mais um dia.

Você não precisa ter nenhuma experiência prévia com programação ou estatística. Precisa só estar disposto a pensar junto.

Se os mortos andam...
...os dados precisam falar.

Quem Está Nessa História?

Antes de mergulhar nos dados, conheça as pessoas que os estão coletando.

Taís Drummond, 34 anos, epidemiologista. Antes da queda, trabalhava no Ministério da Saúde em Brasília modelando surtos de dengue e febre amarela. Metódica, cética, incapaz de dormir sem antes checar os números do dia. É ela quem decide o que analisar e o que ignorar. Quando os outros entram em pânico, Taís abre o RStudio.

Renato Vaz, 22 anos, estudante de estatística, de Recife. Estava no terceiro ano da faculdade quando tudo desabou. Sabe R melhor do que sabe cozinhar, e ainda está aprendendo as duas coisas. É ele quem escreve a maior parte dos códigos. Faz as perguntas que ninguém quer responder: *“Mas e se a gente estiver errado?”*

Conceição Leal, 58 anos, ex-professora de matemática do ensino médio, de Salvador. Não programa. Não sabia o que era um histograma antes do apocalipse. Mas entende de padrões, entende de gente, e tem uma habilidade rara: consegue perceber quando uma explicação não faz sentido para quem está de fora. Nos capítulos técnicos, é ela quem pergunta o que o leitor está pensando — e não descansa enquanto a resposta não for clara.

Os três se encontraram no que restava de um laboratório universitário em Campina Grande, no interior da Paraíba. O gerador ainda funcionava. O servidor ainda tinha R instalado. E havia dados — muitos dados — esperando para ser lidos.

1 Introdução à Ciência de Dados

Conceição encontrou Taís às três da manhã, de pé na frente de uma tela cheia de números.

— Você não dorme? — ela perguntou.

— Durmo depois — Taís respondeu sem tirar os olhos do monitor. — Primeiro os dados.

Conceição puxou uma cadeira. Ela havia sido professora de matemática por trinta anos, mas nunca tinha visto ninguém trabalhar assim: como se os números fossem uma questão de vida ou morte.

Nesse momento, eram.

— Então me explica — disse Conceição. — O que você está fazendo exatamente?

Taís pausou. Respirou fundo.

— Ciência de Dados.

1.1 O Que é Ciência de Dados?

— É um nome bonito — disse Conceição. — Mas o que significa na prática?

Taís girou a cadeira para encarar a professora.

— Significa usar dados para tomar decisões melhores. Coletar informações, organizá-las, analisar os padrões, e extrair alguma conclusão útil. Qualquer coisa que você não conseguiria enxergar só olhando os números brutos.

— Como?

— No nosso caso? — ela apontou para o mapa na parede, coberto de marcadores vermelhos. — Identificar quais cidades estão mais infectadas. Prever para onde a infecção vai se espalhar. Calcular quanto tempo temos antes que uma região fique inviável. Estimar quantas rações um grupo precisa para sobreviver três semanas em rota de fuga.

Conceição olhou para o mapa por um longo momento.

— Então não é só estatística. É decisão.

— Exatamente isso — disse Taís. — Dado sem decisão é só ruído.

Ciência de Dados é o campo que combina estatística, programação e conhecimento de domínio para extrair informação útil a partir de dados. O objetivo final não é calcular médias por calcular — é responder perguntas que importam.

Em um apocalipse zumbi, as perguntas que importam são:

- Quais cidades ainda são seguras?
- A infecção está desacelerando ou vai explodir?
- Qual rota tem menor risco de encontro com infectados?
- Quantos dias de suprimento o grupo precisa?

- Existe algum padrão no comportamento dos zumbis?

Todas essas perguntas têm uma coisa em comum: elas podem ser respondidas com dados, se você souber como analisá-los.

1.2 Por Que R?

Renato chegou com dois copos de café — ou o que passava por café naquele estágio do apocalipse — e ouviu a última parte da conversa.

— Ela perguntou por que R? — ele disse, entregando um copo para cada uma.

— Ainda não — disse Conceição. — Mas ia chegar lá.

Renato sentou no chão com o notebook no colo.

— R é uma linguagem de programação criada especificamente para análise de dados e estatística. É gratuita, de código aberto, e tem uma comunidade enorme que desenvolveu pacotes para praticamente tudo que você possa imaginar: manipulação de dados, visualização, modelos estatísticos, aprendizado de máquina.

— E você sabe usar? — perguntou Conceição.

— Estou no terceiro ano de estatística — ele respondeu. — R é como minha língua nativa.

Taís completou:

— Antes do colapso, eu usava R no Ministério da Saúde para modelar surtos de dengue. A mesma lógica se aplica aqui. Os dados são diferentes, o problema é diferente, mas as ferramentas são as mesmas.

Antes da queda, o R era usado amplamente em diversas áreas:

- **Epidemiologia e saúde pública:** modelos de propagação de doenças, análise de ensaios clínicos, monitoramento de surtos em tempo real. Alguns pesquisadores chegaram perto de prever a disseminação inicial da infecção com modelos em R. Ninguém os ouviu a tempo;
- **Pesquisa acadêmica:** universidades do mundo inteiro usavam R para testes estatísticos, modelagem matemática e análise de séries temporais. Muitos desses relatórios sobrevivem hoje apenas em servidores abandonados;
- **Bioinformática:** análise de DNA, RNA e sequenciamento genético em larga escala. Há quem acredite que os primeiros estudos sobre o agente infeccioso foram feitos com pipelines escritos em R;
- **Finanças e economia:** previsão de tendências, cálculo de risco, modelagem de mercados. Nenhum algoritmo previu o verdadeiro colapso;
- **Visualização de dados:** bibliotecas como `ggplot2` transformavam números em gráficos claros e elegantes. Nos primeiros dias da infecção, dashboards em R mostravam mapas de contágio em tempo real — até a infraestrutura global deixar de existir.

— Agora — disse Renato, abrindo o RStudio — talvez seja a última ferramenta capaz de explicar o caos.

2 Preparando o Ambiente

Na manhã seguinte, Renato ligou o notebook e olhou para Conceição com um sorriso meio constrangido.

— Eu preciso que você instale o R.

Conceição ergueu uma sobrancelha.

— Eu nunca instalei nada na vida. Meu marido sempre fazia isso.

— Seu marido não está aqui — disse Renato. — Mas eu estou. E vou explicar cada passo.

Taís, sem tirar os olhos de uma planilha, acrescentou:

— É mais fácil do que parece. Se você conseguia instalar o Whatsapp, consegue instalar o R.

Conceição olhou para a tela por um longo segundo.

— Tudo bem. Me ensina.

Neste capítulo você vai instalar as duas ferramentas principais do livro: a linguagem R e o ambiente de desenvolvimento RStudio. Não precisa ter experiência com programação. Basta seguir os passos.

2.1 Instalando o R

O R é a linguagem de programação que faz os cálculos. O RStudio é a interface onde você vai escrever e executar seus códigos. Os dois são gratuitos.

Comece pelo R.

Linux (Debian/Ubuntu)

Abra o terminal e execute:

```
sudo apt update
sudo apt install r-base
```

Após a instalação, verifique se funcionou:

```
R --version
```

Se aparecer uma linha com o número da versão, está pronto.

Windows

1. Acesse <https://www.r-project.org/>;
2. Clique em **CRAN**;
3. Escolha qualquer servidor de download;
4. Clique em **Download R for Windows**;
5. Baixe e execute o instalador, avançando com as opções padrão.

2.2 Instalando o RStudio

O RStudio é o ambiente onde você vai trabalhar. Ele não substitui o R — ele usa o R por baixo. Pense assim: o R é o motor, o RStudio é o painel de controle.

Linux

Baixe o pacote correspondente à sua distribuição no site <https://posit.co/download/rstudio-desktop>
No Debian/Ubuntu:

```
sudo dpkg -i rstudio-*.deb  
sudo apt --fix-broken install
```

Windows

1. Acesse <https://posit.co/download/rstudio-desktop>;
2. Baixe a versão **Desktop**;
3. Execute o instalador e conclua com as opções padrão.

2.3 Primeira Execução

Renato abriu o RStudio e girou o notebook para Conceição ver.

— Parece complicado — ela disse.

— Parece. Mas só tem quatro partes que importam.

- **Console:** onde os comandos são executados. Digite aqui e pressione Enter para ver o resultado;
- **Source:** área para escrever scripts. Você escreve o código inteiro aqui antes de executar;
- **Environment:** mostra os objetos carregados na memória — variáveis, tabelas, vetores;
- **Plots:** exibe os gráficos gerados pelo seu código.




Figura 2.1: Interface do RStudio

— Para começar — disse Renato — testa isso no console.

$2 + 2$

O resultado deve ser:

[1] 4

Conceição digitou. O número apareceu.

— Funcionou — ela disse, com uma satisfação que ela mesma não esperava sentir.

— Funcionou — Renato confirmou. — Agora você é uma programadora.

— Não exagera.

2.4 Nosso Primeiro Script

Existe uma diferença entre digitar um comando no console e escrever um script. O console é para testar ideias rápidas. O script é para guardar o trabalho — para que qualquer pessoa possa abrir o arquivo e reproduzir exatamente o que você fez.

Em ciência de dados, **reprodutibilidade** não é detalhe: é princípio fundamental. Se você não consegue mostrar como chegou a um resultado, o resultado não vale.

Crie um novo script:

File -> New File -> R Script

Digite:

```
print("O sistema ainda está operacional.")
```

Execute com **Ctrl + Enter**.

Se a frase aparecer no console, seu ambiente está pronto.

Parte I

Como tudo começou

3 O Primeiro Surto

3.1 Dia 5 Após a Infecção

As comunicações falharam às 02:13 da manhã.

Às 04:40, os primeiros relatos de ataques apareceram nas redes internas dos hospitais.

Às 08:15, Recife já estava parcialmente isolada.

Às 10:00, ninguém mais chamava aquilo de doença.

Renato tinha acabado de chegar ao laboratório quando o sinal de internet caiu pela última vez. Ele ficou olhando para a tela por alguns segundos, esperando voltar. Não voltou. Mas o servidor local ainda estava de pé, e alguém havia deixado arquivos de dados na pasta compartilhada.

Taís entrou no laboratório às 10:47 com uma mochila pesada e uma expressão que Renato ainda não sabia interpretar — aquela mistura de concentração intensa e desespero muito bem controlado.

— Você sabe o que está acontecendo lá fora? — ela perguntou.

— Mais ou menos — ele respondeu.

— Bem. Porque vamos precisar de dados para entender.

Ela jogou a mochila no chão e abriu o notebook.

— Me mostra o que tem aí.

3.2 Seu Primeiro Vetor

Os registros dos primeiros dias de infecção tinham sido recuperados por algum agente de campo cujo nome não constava no arquivo. Apenas os números.

Renato digitou:

```
1 infectados <- c(3, 7, 18, 45, 121)
2 infectados
```

— Isso representa o número de novos infectados por dia — ele explicou. — Dias 1 ao 5.

Conceição, que havia chegado logo depois carregando dois sacos de comida, colocou tudo no chão e olhou para a tela.

— O que é esse símbolo de setinha?

— O `<-` é o operador de atribuição em R — disse Renato. — É o jeito de dar um nome a um valor. Aqui, estou dizendo: “crie um objeto chamado `infectados` e guarde esses cinco números nele”.

— E o `c()`?

— A função `c()` serve para **combinar** múltiplos valores em um único objeto. Em R, chamamos isso de **vetor**. Pense como uma lista numerada que o R consegue manipular de uma vez só.

Conceição assentiu devagar.

— Então `infectados` agora é uma lista com cinco números.

— Exatamente.

3.3 Analisando os Dados

Taís olhou para os números por alguns segundos.

— 3, 7, 18, 45, 121 — ela repetiu em voz baixa. — Isso não é crescimento linear.

— Não — concordou Renato.

— Qual é a média?

— Posso calcular agora.

Ele digitou:

```
1 # Média de infectados por dia
2 mean(infectados)
3
4 # Maior número registrado
5 max(infectados)
6
7 # Total acumulado de casos
8 sum(infectados)
9
10 # Menor número registrado
11 min(infectados)
12
13 # Mediana da distribuição
14 median(infectados)
15
16 # Desvio padrão
17 sd(infectados)
```

— Espera — disse Conceição. — O que é cada uma dessas coisas?

Renato se virou na cadeira.

3.3.1 Estatística Descritiva: uma visão geral

— Quando você tem um conjunto de números, precisa de formas de resumir o que eles dizem. Isso se chama **estatística descritiva**. As principais medidas se dividem em quatro grupos:

- **Tendência central:** qual é o valor típico? Usamos média, mediana e moda;
- **Dispersão:** os valores estão espalhados ou concentrados? Usamos desvio padrão, variância, mínimo e máximo;
- **Posição:** onde está um valor em relação aos outros? Usamos quartis e percentis;

- **Forma:** a distribuição é simétrica? Está inclinada para algum lado? Usamos assimetria (*skewness*) e curtose (*kurtosis*).

— No contexto do surto — acrescentou Taís, sem tirar os olhos da tela — essas medidas são a diferença entre sentir que a situação piorou e conseguir provar quanto ela piorou.

3.3.2 O que cada função calcula

- `mean()`: calcula a **média aritmética** — soma todos os valores e divide pelo número de observações. Resume o nível médio de infecção no período;
- `max()`: retorna o **maior valor** observado, revelando o pico de contaminação;
- `sum()`: soma todos os valores — indica o total acumulado de casos;
- `min()`: retorna o **menor valor**, fornecendo a referência de menor intensidade observada;
- `median()`: encontra o **valor central** quando os dados estão ordenados. É menos sensível a valores extremos do que a média;
- `sd()`: calcula o **desvio padrão**, que mede o quanto os valores variam em torno da média. Quanto maior, mais instável é a propagação. Vamos explorar esse conceito a fundo no próximo capítulo.

3.3.3 Medidas de posição: quartis

— Tem mais uma coisa útil — disse Renato. — Os quartis.

— Que são...? — perguntou Conceição.

— Imagine que você coloca todos os valores em ordem crescente e divide em quatro partes iguais. Cada divisão é um quartil:

- **Q1 (primeiro quartil):** 25% dos valores estão abaixo deste ponto;
- **Q2 (segundo quartil):** é a mediana. Metade dos valores estão abaixo, metade acima;
- **Q3 (terceiro quartil):** 75% dos valores estão abaixo deste ponto.

A diferença entre Q3 e Q1 chama-se **intervalo interquartil (IQR)**. Ele mostra onde estão os 50% centrais dos dados, ignorando os extremos.

```
1 # Quartis
2 quantile(infectados)
3
4 # Intervalo interquartil
5 IQR(infectados)
```

— Em um surto — disse Taís — um IQR muito alto indica que a propagação está instável. Dias relativamente calmos intercalados com explosões de casos. Exatamente o que é mais difícil de gerenciar.

3.3.4 Interpretando os resultados

Renato executou tudo e virou o notebook para as duas verem.

— O que os números dizem — resumiu Taís — é que isso não é um surto controlável. A média não representa bem a situação porque os valores são muito assimétricos. O último dia teve quase o quádruplo do penúltimo. Isso é crescimento exponencial.

— O que significa que se não fizermos nada... — começou Conceição.

— Significa que a mediana hoje é 18. Em uma semana, pode ser 10.000.

Silêncio.

3.3.5 Visualizando os dados com um gráfico de linha

— Deixa eu mostrar uma coisa — disse Renato.

Ele digitou rapidamente:

```
1 plot(
2   infectados,
3   type = "o",
4   col  = "darkred",
5   pch  = 19,
6   xlab = "Dias",
7   ylab = "Número de Infectados",
8   main = "Crescimento da Infecção Zumbi"
9 )
```

O gráfico apareceu na tela. Conceição não disse nada por um longo momento.

Cinco pontos. Cinco dias. Uma linha que começava quase horizontal e subia cada vez mais íngreme.

— Você não precisava do gráfico para entender — disse Renato. — Mas ele torna impossível fingir que não está vendo.

A infecção não cresce de forma linear. Ela acelera.

Esse padrão é particularmente perigoso porque dá uma falsa sensação de controle nos primeiros dias. No dia 1, são apenas 3 casos. No dia 2, apenas 7. Parece gerenciável. Mas a aceleração já está embutida nos dados desde o início.

Quando os pontos começam a subir rapidamente, talvez seja tarde demais para fechar os portões da cidade.

3.4 Instalando o Tidyverse

— Antes de continuar — disse Renato — preciso instalar um pacote.

— O R não já tem tudo? — perguntou Conceição.

— O R base tem muita coisa, mas existem pacotes desenvolvidos pela comunidade que tornam a vida muito mais fácil. O principal deles se chama **tidyverse**.

O **tidyverse** é um conjunto de pacotes pensados para trabalhar em conjunto: importar dados, organizá-los, transformá-los e visualizá-los de forma consistente e legível. Vamos usá-lo ao longo de todo o livro.

```
1 install.packages("tidyverse")
```

Aguarde a instalação. Depois, carregue o pacote:

```
1 library(tidyverse)
```

Você vai ver algumas mensagens aparecerem no console. Isso é normal — é o R informando quais pacotes internos do tidyverse foram carregados.

3.5 O Primeiro Dataset

Taís abriu uma pasta no servidor e apontou para um arquivo.

— Isso aqui veio de um servidor militar antes do sinal cair. Dados de vinte e uma cidades.

O arquivo se chamava:

`surto_zumbi.csv`

Conteúdo:

Tabela 3.1: Dados do surto zumbi por cidade

Cidade	Infectados	Sobreviventes	Rações Totais
São Paulo	8.384.400	3.498.961	22.723.937
Rio de Janeiro	4.590.000	1.943.760	26.063.045
Curitiba	1.332.800	602.064	6.492.614
Belo Horizonte	1.574.200	689.594	6.333.163
Porto Alegre	958.120	428.760	1.660.254
Florianópolis	203.055	294.004	1.138.364
Goiânia	997.100	513.942	1.386.103
Brasília	1.648.136	1.228.987	15.232.204
Salvador	1.972.000	842.618	7.763.359
Recife	1.122.000	486.017	5.101.657
Fortaleza	1.836.000	795.859	1.788.306
Natal	605.200	265.548	3.621.787
João Pessoa	535.621	276.755	3.318.101
Maceió	697.000	295.005	1.341.703
Aracaju	372.170	276.062	1.154.463
Teresina	591.600	242.564	1.018.975
São Luís	758.200	334.109	1.888.018
Belém	1.020.000	455.622	3.780.330
Cuiabá	279.485	318.406	2.287.218
Manaus	1.530.000	641.176	3.523.101
Porto Velho	374.000	154.816	1.446.327

— Isso é muito dado — disse Conceição.

— Isso é pouco dado — respondeu Taís. — Mas é o que temos.

3.6 Importando Dados

Para carregar o arquivo no R:

```
1 surto <- read.csv("surto_zumbi.csv")
```

Para visualizar o conteúdo:

```
1 surto
```

O R vai exibir a tabela no console. Se quiser uma visualização mais confortável, use:

```
1 View(surto)
```

Isso abre uma aba separada no RStudio com os dados em formato de planilha.

3.7 Resumo Estatístico

Com um dataset carregado, o primeiro passo é sempre obter um panorama geral:

```
1 summary(surto)
```

O comando `summary()` calcula automaticamente, para cada coluna numérica:

- mínimo e máximo;
- média e mediana;
- primeiro e terceiro quartis.

É o equivalente a pedir um briefing rápido: em segundos, você tem uma visão de toda a distribuição de cada variável.

3.8 Visualizando a Catástrofe

— Quero ver isso em gráfico — disse Taís.

Renato digitou:

```
1 par(mar = c(10, 4, 2, 2))
2 barplot(
3   height      = surto$Infectados,
4   names.arg   = surto$Cidade,
5   las        = 2,
6   col         = "steelblue",
7   ylab        = "Infectados"
8 )
```

O gráfico mostrou barras de alturas muito diferentes. Uma delas era muito maior do que todas as outras.

São Paulo havia se tornado um epicentro da infecção. O gráfico deixava isso inegável.

— Isso não era visível só olhando a tabela — disse Conceição.

— Não — concordou Taís. — A visualização força você a encarar a escala. São Paulo tem quase o dobro do segundo colocado. Isso muda completamente as prioridades de onde alocar recursos.

3.9 Missão do Capítulo

Antes de avançar, certifique-se de que você consegue:

1. criar um vetor em R com `c()` e atribuí-lo a uma variável com `<-`;
2. calcular média, mediana, máximo, mínimo, soma, desvio padrão, quartis e IQR;
3. importar um arquivo CSV com `read.csv()`;
4. gerar um resumo estatístico com `summary()`;
5. criar um gráfico de linha com `plot()` e um gráfico de barras com `barplot()`.

3.10 Fim do Dia

À meia-noite, depois que Conceição tinha ido dormir e Renato estava prestes a fazer o mesmo, um novo arquivo apareceu na pasta compartilhada do servidor.

Taís olhou para o nome do arquivo por um longo tempo.

`paciente_zero.rds`

Ninguém havia colocado aquele arquivo ali. Ela tinha certeza.

Alguém ainda estava vivo. E estava tentando mandar uma mensagem.

4 A Curva Que Ninguém Viu

Taís ficou parada diante da tela por quase um minuto.

Na janela do RStudio havia apenas números: tempos de transformação registrados nos últimos dias por agentes de campo que, provavelmente, já não existiam mais. Ela havia visto tabelas assim centenas de vezes na sua carreira. Mas desta vez, o que estava em jogo não era uma publicação científica.

— Renato — ela chamou sem tirar os olhos da tela. — Você sabe fazer um histograma?

Renato se aproximou com o notebook debaixo do braço.

— Claro. Por quê?

— Porque preciso enxergar isso. Não ler. *Enxergar*.

4.1 O Que é um Histograma?

Conceição, que estava organizando suprimentos no canto da sala, parou ao ouvir a conversa.

— Um histo... o quê?

— Histograma — Renato repetiu. — É um tipo de gráfico. Mas deixa eu explicar.

Ele puxou uma cadeira.

— Imagina que você tem uma lista de números. Nesse caso, são os tempos que cada infectado levou para se transformar, em horas:

68, 71, 75, 70, 74, 72, 69, 76, 73, 71,
72, 70, 68, 74, 77, 73, 72, 69, 71, 75

— Parece uma sopa — disse Conceição.

— Exatamente. À primeira vista, é difícil ver qualquer coisa. Mas quando a gente *agrupa* esses valores em faixas, começa a aparecer um padrão.

Renato escreveu no papel:

Faixa (horas)	Quantidade de casos
68 – 70	6
71 – 73	8
74 – 76	5
77 – 79	1

— Agora dá para ver que a maioria se transformou entre 71 e 73 horas — Conceição percebeu.

— Isso. E o histograma é exatamente essa tabela, mas desenhada. Cada faixa vira uma barra. Quanto mais casos naquela faixa, mais alta é a barra.

O **histograma** é um gráfico que mostra como os dados estão distribuídos. Ele divide os valores em intervalos — chamados de **classes** ou **bins** — e representa a frequência de cada intervalo como uma barra vertical.

A altura de cada barra responde à pergunta: “*Quantos valores caíram nessa faixa?*”

4.2 Por Que Isso Importa?

— Tudo bem — disse Conceição. — Mas por que não olhar a tabela direto?

Taís se virou na cadeira.

— Porque com vinte casos é fácil. Com mil casos, a tabela não diz nada. O histograma te dá a *forma* dos dados de um jeito que o olho humano processa em segundos.

Com o histograma, conseguimos identificar:

- **onde os dados se concentram:** qual é a faixa mais comum;
- **se os dados são simétricos:** ou se estão puxados para um lado;
- **valores extremos:** casos muito fora do padrão que merecem investigação;
- **grupos distintos:** às vezes aparecem dois picos, indicando que existem dois tipos de comportamento nos dados.

— É como se o gráfico te contasse uma história que os números não conseguem contar sozinhos — resumiu Renato.

— Exatamente isso — Taís concordou. E voltou para o teclado.

4.3 Construindo um Histograma em R

Renato abriu o RStudio. Eles tinham registros de mil infectados simulados a partir dos dados de campo — volume suficiente para o padrão aparecer com clareza.

```

1 # Fixamos a semente para garantir reprodutibilidade
2 set.seed(42)
3
4 # Simulamos 1000 tempos de progressao da infeccao
5 tempo_progressao <- rnorm(n      = 1000,
6                           mean   = 72,
7                           sd     = 12)
8
9 # Geramos o histograma
10 hist(tempo_progressao,
11       main   = "Tempo de Progressao da Infeccao",
12       xlab   = "Horas ate a transformacao",
13       ylab   = "Frequencia",
14       col    = "darkred",
15       border = "white")

```

Linha por linha:

- `set.seed(42)`: garante que os números “aleatórios” gerados sejam sempre os mesmos. Isso torna o experimento **reproduzível** — qualquer pessoa que rodar esse código vai obter exatamente o mesmo gráfico;
- `rnorm()`: gera valores aleatórios que seguem uma distribuição normal — falaremos mais sobre isso em breve;
- `n = 1000`: queremos 1000 observações simuladas;
- `mean = 72`: a média dos tempos de transformação é 72 horas;
- `sd = 12`: o desvio padrão é 12 horas — uma medida de espalhamento que exploraremos no próximo capítulo;
- `hist()`: cria o histograma;
- `main, xlab, ylab`: título e rótulos dos eixos;
- `col` e `border`: cores das barras e das bordas.

O gráfico apareceu na tela. Renato se afastou um pouco para todos verem.

A forma era inconfundível: as barras começavam baixas, subiam até um pico no centro, e desciam de volta. Como um sino.

— A maioria se transformou perto das 72 horas — Conceição observou. — Poucos muito antes, poucos muito depois.

— Exato — disse Taís. — E isso tem um nome.

4.4 O Que é uma Distribuição de Probabilidade?

— Antes de falar do nome — disse Renato — deixa eu explicar o que está por trás.

Quando coletamos muitos dados do mesmo fenômeno, percebemos que eles não se distribuem aleatoriamente. Existe um *padrão*. Alguns valores aparecem com muito mais frequência do que outros.

Uma **distribuição de probabilidade** é um modelo matemático que descreve esse padrão. Em vez de dizer “temos esses 1000 valores específicos”, ela diz: “*valores nessa faixa são comuns; valores muito fora dela são raros.*”

Com uma distribuição, conseguimos responder perguntas como:

- “Qual a chance de alguém se transformar em menos de 48 horas?”
- “Quanto tempo temos antes que metade dos infectados vire ameaça?”
- “Qual o prazo máximo realista para evacuar uma área?”

— Então a distribuição é uma ferramenta de previsão — disse Conceição.

— É isso — confirmou Renato. — Os dados que temos descrevem o passado. A distribuição nos ajuda a projetar o futuro.

4.5 Variáveis Discretas e Contínuas

Taís fez uma pausa.

— Antes de falar sobre a distribuição normal, tem uma distinção que precisamos entender. Nem todos os dados são do mesmo tipo.

Variáveis discretas

Variáveis discretas são **contáveis**. Os valores possíveis são inteiros separados — não existe “2,7 zumbis”.

Exemplos no contexto do surto:

- número de zumbis avistados em uma rua;
- quantidade de sobreviventes em um abrigo;
- número de ataques registrados em um dia.

Variáveis contínuas

Variáveis contínuas podem assumir **qualquer valor dentro de um intervalo**. Entre 72h e 73h existem infinitos valores possíveis: 72,1h, 72,53h, 72,998h...

Exemplos:

- tempo até a transformação;
- temperatura corporal dos infectados;
- distância percorrida por um grupo em fuga.

— Essa distinção importa — disse Taís — porque diferentes tipos de variáveis pedem diferentes modelos matemáticos. Os tempos de transformação são contínuos, e é por isso que o modelo que os descreve bem é a distribuição que apareceu no nosso gráfico.

4.6 Distribuição Normal

A **distribuição normal** — também chamada de **gaussiana** — é a distribuição mais importante da estatística. Ela aparece em fenômenos naturais o tempo todo: altura de pessoas, pressão arterial, erros de medição, resultados de provas.

Por quê ela aparece tanto? Porque quando muitos fatores independentes e pequenos influenciam um resultado ao mesmo tempo, a tendência é que os valores se acumulem no centro e diminuam nas extremidades. É o que acontece com o tempo de transformação: genética do infectado, dose recebida, estado imunológico, temperatura ambiente — tudo isso contribui um pouquinho, e o resultado segue essa curva em forma de sino.

4.6.1 Os dois parâmetros da distribuição normal

A forma exata da curva depende de dois parâmetros:

- μ (“mu”) — a **média**: define onde está o centro da curva. Se $\mu = 72$, a maioria dos casos se concentra perto das 72 horas;
- σ (“sigma”) — o **desvio padrão**: controla o quanto os valores se espalharam em torno da média. Uma curva com desvio padrão pequeno é estreita e pontuda. Uma curva com desvio padrão grande é larga e achatada.

— Espera — Conceição levantou a mão. — Desvio padrão. Já vi esse nome antes lá atrás. O que exatamente ele mede?

— Boa pergunta — disse Taís. — E merece resposta direito. Vamos dedicar o próximo capítulo a isso. Por enquanto, guarda o seguinte: desvio padrão mede o *espalhamento*. Quanto maior, mais os valores variam. Quanto menor, mais eles ficam agrupados perto da média.

4.7 A Regra 68–95–99,7

Renato foi até o quadro branco.

— Tem uma propriedade da distribuição normal que é muito útil na prática. Se você sabe a média e o desvio padrão, consegue estimar onde a maioria dos casos vai cair.

Ele escreveu:

Faixa em torno da média	Proporção dos dados
Média $\pm$ 1 desvio padrão	$\approx 68\%$
Média $\pm$ 2 desvios padrão	$\approx 95\%$
Média $\pm$ 3 desvios padrão	$\approx 99,7\%$

— Nos nossos dados, a média é 72 horas e o desvio padrão é 12 horas. Então:

- cerca de **68%** dos infectados se transformarão entre **60h e 84h** ($72 - 12 = 60$; $72 + 12 = 84$);
- cerca de **95%** se transformarão entre **48h e 96h**;
- cerca de **99,7%** se transformarão entre **36h e 108h**.

Conceição calculou mentalmente.

— Então um infectado que ainda não virou em 108 horas é...

— Extremamente raro — Taís completou. — Menos de 0,3% dos casos. Isso não significa impossível. Significa que, se aparecer, precisa ser investigado. Pode ser uma variação do agente. Pode ser imunidade parcial. Pode ser erro de registro. Valores muito fora do padrão sempre merecem atenção.

— Ou podem ser uma oportunidade — disse Renato baixinho, olhando para o gráfico. Ninguém respondeu.

A curva continuava lá, perfeita, simétrica, indiferente ao mundo que havia deixado de existir lá fora.

4.8 Missão do Capítulo

Antes de avançar, certifique-se de que você consegue:

1. explicar o que é um histograma e para que ele serve;
2. construir um histograma em R com a função `hist()`;
3. distinguir variáveis discretas de variáveis contínuas e dar exemplos de cada;
4. descrever com suas próprias palavras o que é uma distribuição de probabilidade;
5. descrever o que é uma distribuição normal e seus dois parâmetros (μ e σ);
6. aplicar a regra 68–95–99,7 para estimar proporções de uma distribuição.

No próximo capítulo, vamos destrinchar o desvio padrão — a medida que Conceição está esperando entender desde o início.

`paciente_zero.rds`

O arquivo ainda estava lá. Taís não havia tido coragem de abrir.

Alguém, em algum lugar, ainda continuava coletando dados.

5 O Quanto Você Pode Errar

Conceição acordou antes dos outros.

Ela tinha o hábito, de antes: levantar cedo, tomar café, revisar as aulas do dia. Agora não havia aulas, não havia café de verdade, e o dia não tinha uma estrutura clara além de “sobreviver”. Mas o hábito ficou.

Ela ficou olhando para o quadro branco onde Renato havia escrito, na noite anterior:

$$sd = 12$$

Desvio padrão. Ela conhecia a fórmula. Havia ensinado a fórmula. Mas naquela manhã, sozinha no laboratório com o gerador zumbindo baixinho, ela percebeu que sabia calcular sem saber, de fato, o que o número *significava*.

Quando Renato chegou, ela já tinha a pergunta pronta.

— Me explica o desvio padrão. De verdade. Sem fórmula primeiro.

Renato pousou o copo e pensou por um segundo.

— Tudo bem. Vou tentar.

5.1 O Problema da Média

— Imagina dois grupos de sobreviventes — ele começou. — Cada grupo tem cinco pessoas. Eu pergunto a idade de cada uma.

Ele escreveu no quadro:

Grupo A: 30, 31, 30, 29, 30

Grupo B: 10, 18, 30, 45, 47

— Qual é a média dos dois grupos?

Conceição calculou mentalmente em segundos.

— Os dois têm média 30.

— Exato. Mas esses dois grupos são a mesma coisa?

Ela olhou para os números.

— Claro que não. No grupo A, todo mundo tem quase a mesma idade. No grupo B, tem criança e tem quase idoso.

— E aí está o problema da média — disse Renato. — Ela resume, mas esconde. Dois conjuntos completamente diferentes podem ter a mesma média. Para entender os dados de verdade, você precisa saber não só *onde* estão os valores, mas *o quanto eles variam*.

— E é isso que o desvio padrão mede.

— Isso.

5.2 A Ideia por Trás do Desvio Padrão

Taís entrou com um bloco de notas e sentou sem dizer nada, como era seu hábito quando queria ouvir.

— O desvio padrão — continuou Renato — responde à seguinte pergunta: *em média, o quanto cada valor se afasta da média?*

— Peraí — disse Conceição. — “Em média, o quanto cada valor se afasta da média.” Isso soa circular.

— Soa, mas não é. Deixa eu mostrar passo a passo.

Ele usou o Grupo A como exemplo: 30, 31, 30, 29, 30. Média = 30.

1. Calcule a distância de cada valor até a média:

$$30 - 30 = 0$$

$$31 - 30 = 1$$

$$30 - 30 = 0$$

$$29 - 30 = -1$$

$$30 - 30 = 0$$

2. O problema: se você somar essas distâncias, os negativos cancelam os positivos. O resultado é sempre zero. Precisamos eliminar os sinais negativos — e fazemos isso **elevando ao quadrado**:

$$0^2 = 0 \quad 1^2 = 1 \quad 0^2 = 0 \quad (-1)^2 = 1 \quad 0^2 = 0$$

3. Calcule a média dessas distâncias ao quadrado. Isso se chama **variância**:

$$\text{Variância} = \frac{0 + 1 + 0 + 1 + 0}{5} = 0,4$$

4. A variância está em unidades ao quadrado — horas², pessoas², o que for. Para voltar à unidade original, tiramos a raiz quadrada:

$$\text{Desvio padrão} = \sqrt{0,4} \approx 0,63$$

— Agora faz o mesmo para o Grupo B — disse Conceição, já com o lápis na mão.

Ela calculou. Chegou em aproximadamente 14,8.

— Grupo A tem desvio padrão de 0,63. Grupo B tem desvio padrão de 14,8 — ela resumiu. — E isso quer dizer que no grupo B os valores são muito mais espalhados.

— Exatamente. O desvio padrão é uma **régua de espalhamento**. Quanto maior, mais os dados variam em torno da média. Quanto menor, mais eles estão concentrados.

5.3 Calculando em R

Taís abriu o notebook.

— Na prática, ninguém calcula isso à mão. O R faz em uma linha.

```

1      grupo_a <- c(30, 31, 30, 29, 30)
2      grupo_b <- c(10, 18, 30, 45, 47)
3
4      sd(grupo_a)  # resultado: ~0.63
5      sd(grupo_b)  # resultado: ~14.8
6
7      var(grupo_a) # variancia do grupo A
8      var(grupo_b) # variancia do grupo B

```

— A função `sd()` calcula o desvio padrão. A função `var()` calcula a variância — que é o desvio padrão antes de tirar a raiz quadrada.

Conceição olhou para as duas funções.

— Quando uso uma, quando uso a outra?

— Na maioria dos casos, você vai usar `sd()` — respondeu Renato. — O desvio padrão está na mesma unidade dos seus dados, então é mais fácil de interpretar. A variância aparece mais em fórmulas matemáticas do que em análises do dia a dia.

5.4 De Volta aos Infectados

Taís virou o notebook e abriu o script da noite anterior.

— Deixa eu mostrar por que isso importa para o que estamos analisando.

```

1      set.seed(42)
2
3      # Simulamos dois cenarios de progressao da infeccao
4      surto_controlado <- rnorm(n = 1000, mean = 72, sd = 4)
5      surto_imprevisto <- rnorm(n = 1000, mean = 72, sd = 20)
6
7      # Comparamos os desvios padrao
8      sd(surto_controlado)
9      sd(surto_imprevisto)
10
11     # Visualizamos os dois histogramas lado a lado
12     par(mfrow = c(1, 2))
13
14     hist(surto_controlado,
15          main = "Surto Controlado (sd=4)",
16          xlab = "Horas",
17          col = "steelblue",
18          border = "white",
19          xlim = c(20, 130))
20
21     hist(surto_imprevisto,
22          main = "Surto Imprevisto (sd=20)",
23          xlab = "Horas",
24          col = "darkred",
25          border = "white",
26          xlim = c(20, 130))
27
28     par(mfrow = c(1, 1)) # restaura o layout

```

Os dois gráficos apareceram lado a lado na tela. Os dois tinham média 72. Mas eram completamente diferentes.

O primeiro mostrava uma curva estreita e alta, concentrada. O segundo, uma curva larga e achatada, espalhada por quase todo o eixo horizontal.

— No surto controlado — disse Taís — quase todos os infectados se transformam entre 68 e 76 horas. Você sabe exatamente quando precisa agir.

— No surto imprevisto — disse Renato — tem gente se transformando em 30 horas e tem gente que passa de 110. Você não consegue planejar nada com base na média porque a variação é enorme.

Conceição ficou olhando para os dois gráficos por um momento.

— O desvio padrão alto não é só um número maior. É incerteza.

— É isso — disse Taís. — Em epidemiologia, desvio padrão alto significa que o agente infeccioso está se comportando de forma imprevisível. Pode ser que existam subgrupos na população reagindo de forma diferente. Pode ser que o vírus esteja mutando. Pode ser que os dados estejam sendo coletados de forma inconsistente.

— Ou as três coisas ao mesmo tempo — disse Renato.

— Ou as três coisas ao mesmo tempo.

5.5 Uma Nota Sobre Amostras

Conceição estava prestes a fechar o caderno quando lembrou de algo.

— Quando eu ensinava isso, tinha uma diferença entre dividir por n e dividir por $n - 1$. Por que isso?

Renato ergueu as sobrancelhas.

— Boa memória. Isso é o **desvio padrão amostral**.

Taís explicou:

— Quando você calcula o desvio padrão de uma *população inteira* — todos os infectados do planeta, por exemplo — divide por n . Mas quando você tem apenas uma *amostra* da população, divide por $n - 1$.

— Por quê?

— Porque amostras tendem a subestimar a variação real da população. Dividir por $n - 1$ em vez de n corrige esse viés, dando um resultado ligeiramente maior e mais honesto. Esse ajuste tem nome: chama-se **correção de Bessel**.

— O R usa $n - 1$ por padrão na função `sd()` — completou Renato. — Porque na prática, quase sempre estamos trabalhando com amostras, não com populações inteiras.

Conceição anotou.

— Então quando eu calculei à mão usando n , eu estava calculando o desvio padrão populacional.

— Isso. Para os nossos propósitos aqui, a diferença é pequena quando o número de observações é grande. Mas é importante saber que existe.

5.6 Missão do Capítulo

Antes de avançar, certifique-se de que você consegue:

1. explicar, sem usar a fórmula, o que o desvio padrão mede;
2. descrever os passos que levam da média à variância e ao desvio padrão;

3. calcular desvio padrão e variância em R com `sd()` e `var()`;
4. interpretar a diferença prática entre dois conjuntos com mesma média e desvios padrão diferentes;
5. explicar por que o R divide por $n - 1$ em vez de n .

Taís ainda estava olhando para o gráfico do surto imprevisto quando os outros foram dormir.

O desvio padrão era 20. O dobro do que aparecia nos registros das primeiras semanas.

Ou os dados de campo estavam errados.

Ou alguma coisa havia mudado no agente infeccioso.

Ela abriu uma nova aba no RStudio e começou a digitar.